

Reconnaissance
de la parole

Reconnaissance
d'ondes sonores

Compression
d'images

Contexte
multilocuteurs

Pré-requis

Pré-
traitement

Architecture
NetTalk

Simulation
NetTalk

Complément

Extraction de
caractéristiques

Données d'entrée

Données de sortie

Mise en œuvre

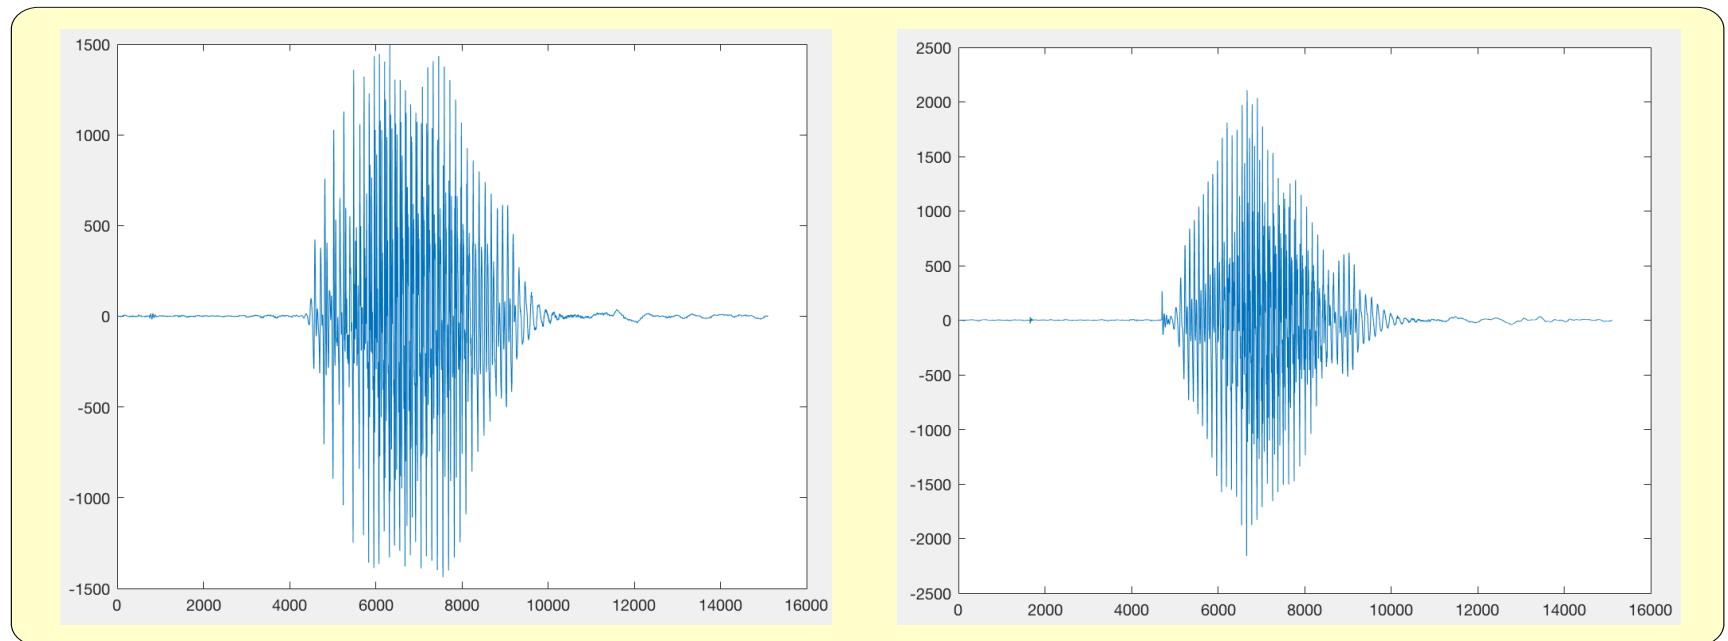
Contexte du laboratoire 2

Nature du signal de parole

Fenêtrage

MFCC

Paramètres utilisés



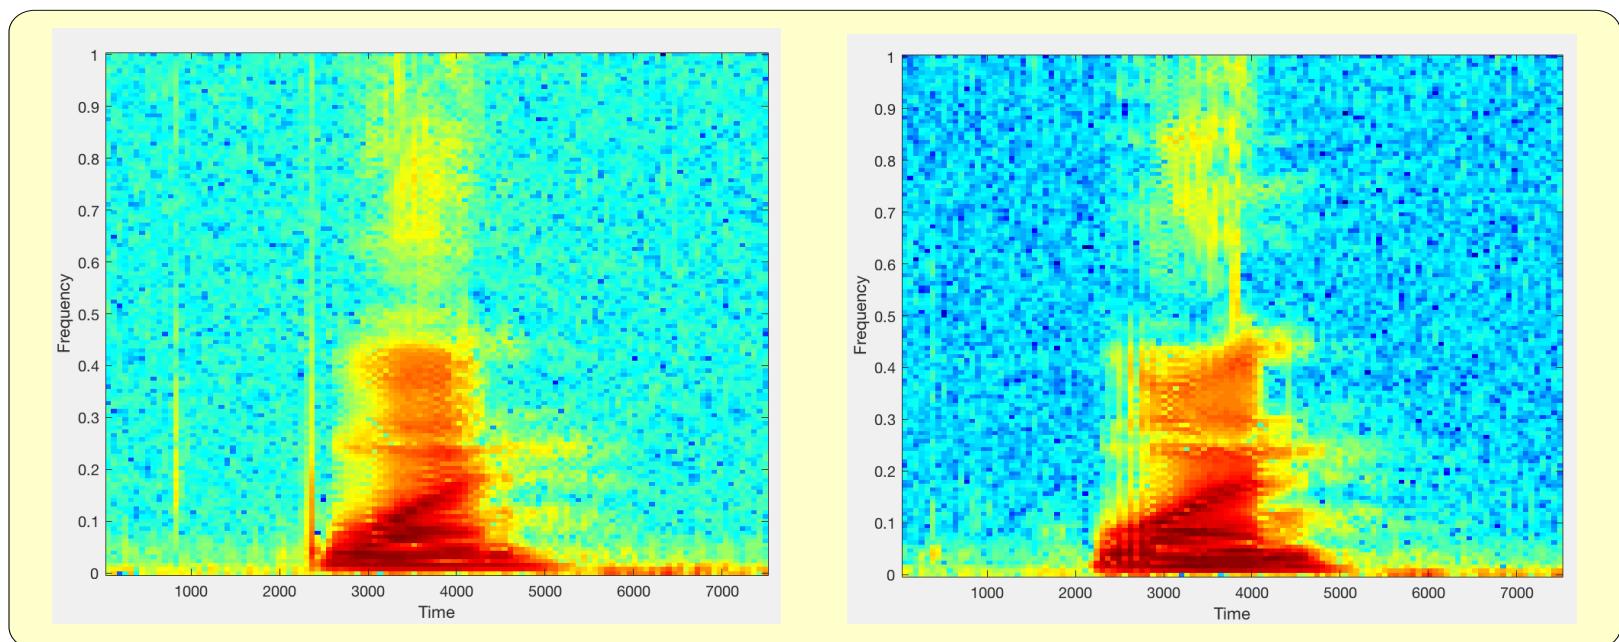
Signal audio du mot « one » prononcé par la même personne à deux intervalles de temps différents. Représentation dans le domaine temporel.

Nature du signal de parole

Fenêtrage

MFCC

Paramètres utilisés



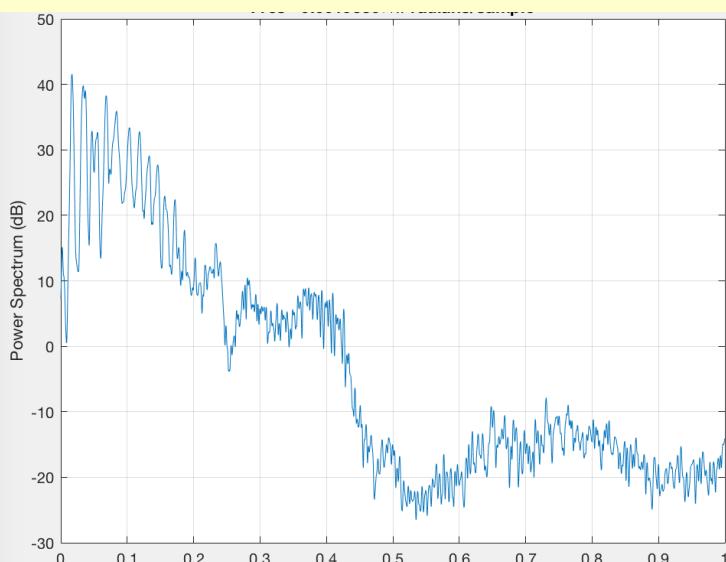
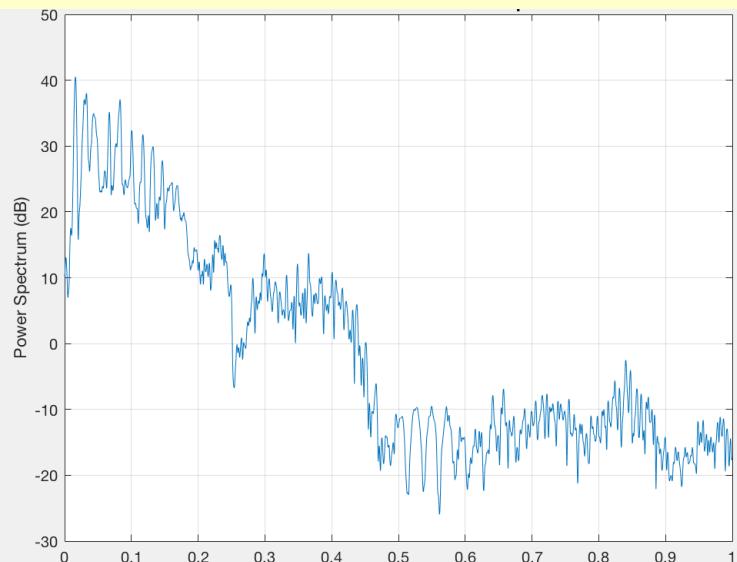
Spectrogramme du signal audio du mot « one » prononcé par la même personne à deux intervalles de temps différents.

Nature du signal de parole

Fenêtrage

MFCC

Paramètres utilisés



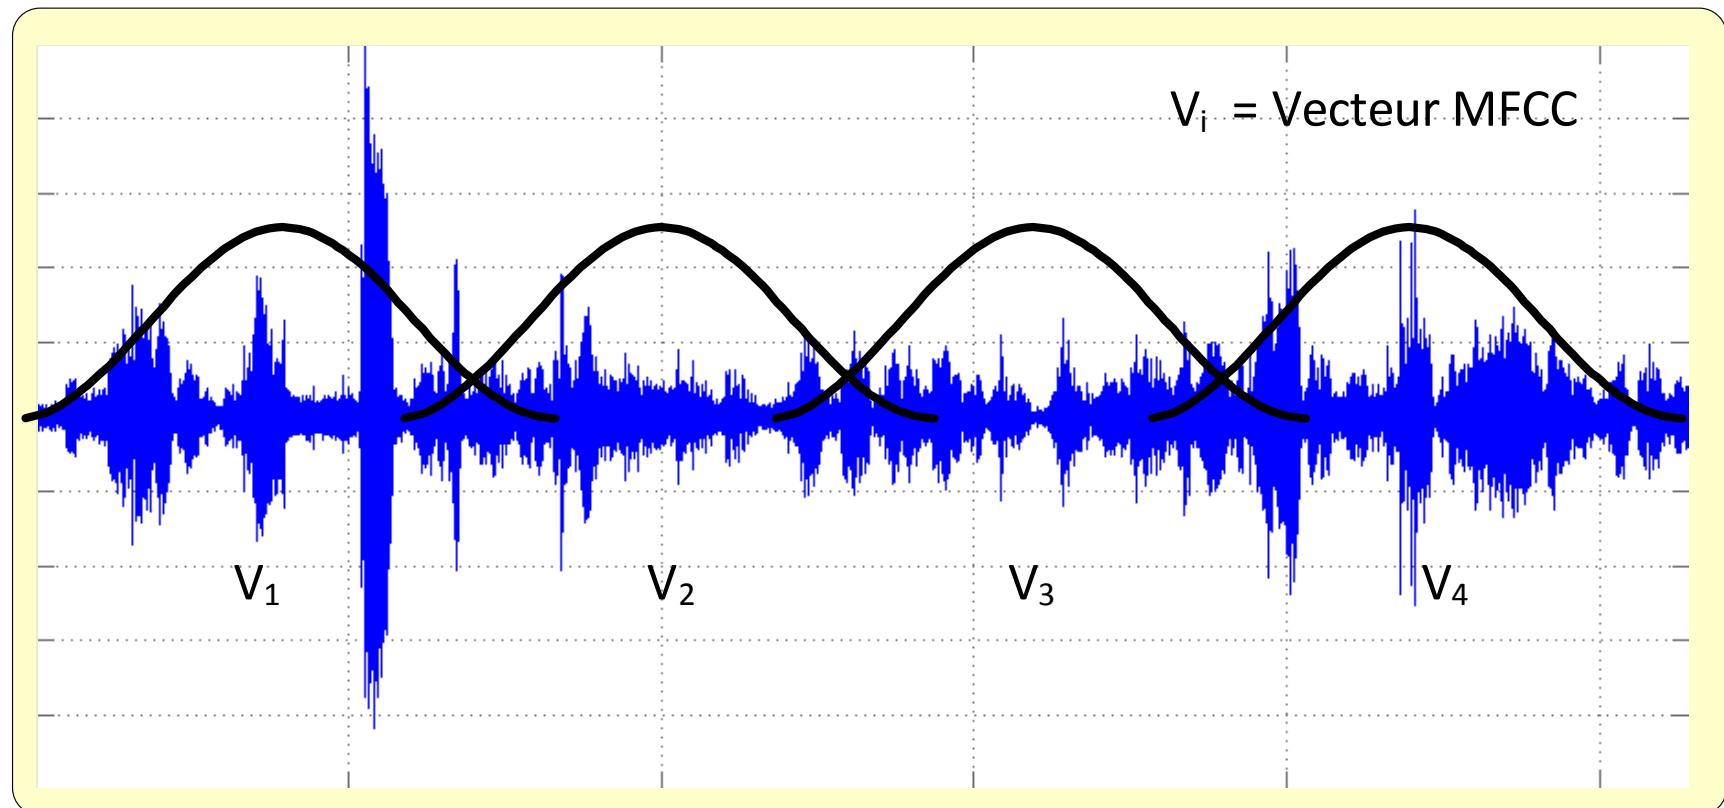
Spectre du signal audio du mot « one » prononcé par la même personne à deux intervalles de temps différents.

Nature du signal de parole

Fenêtrage

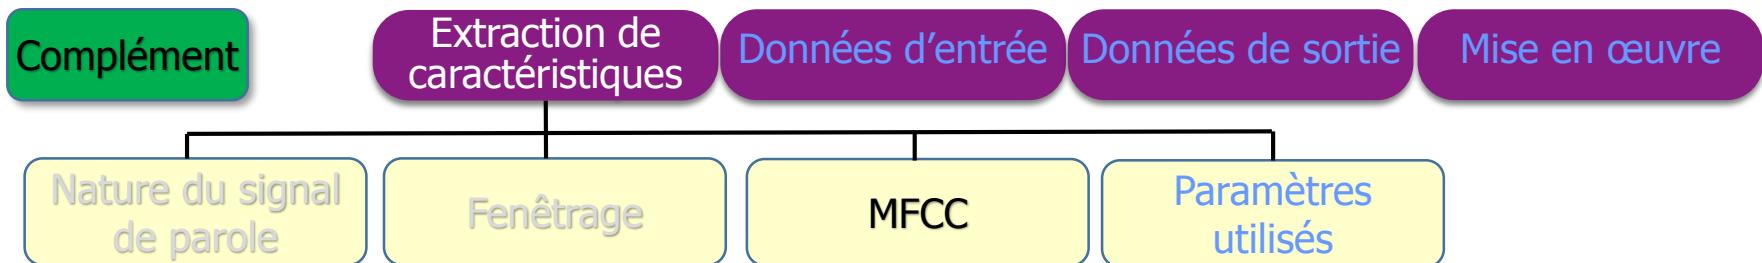
MFCC

Paramètres utilisés



Technique de fenêtrage

- Délimiter le signal
- Stationnarité



- **Calcul des MFCC :** Mel-Frequency Cepstral Coefficients
 - Le spectre de puissance du signal est calculé
 - Les coefficients cepstraux sont calculés à partir d'une transformée en cosinus discrète du spectre obtenu
 - Les bandes de fréquence de ce spectre sont espacées logarithmiquement selon l'échelle de Mel.
- **Pourquoi les MFCC ?**
 - Le signal de parole est modélisé par la convolution de la fonction de transfert du conduit vocal (filtre) avec le signal d'excitation (source).
 - La représentation cepstrale permet de dissocier la source du filtre pour estimer la fréquence fondamentale ou les formants.

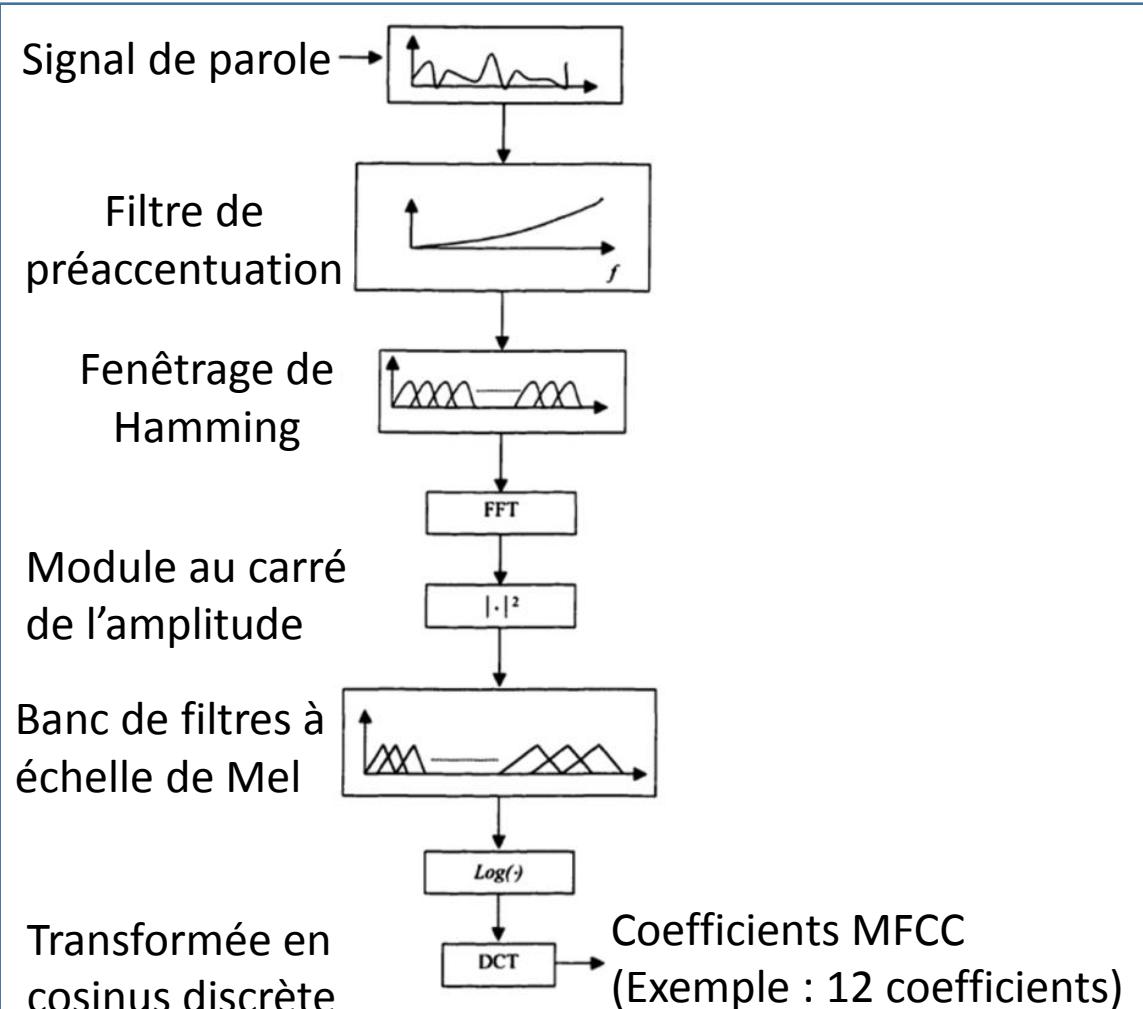


Nature du signal de parole

Fenêtrage

MFCC

Paramètres utilisés



DCT

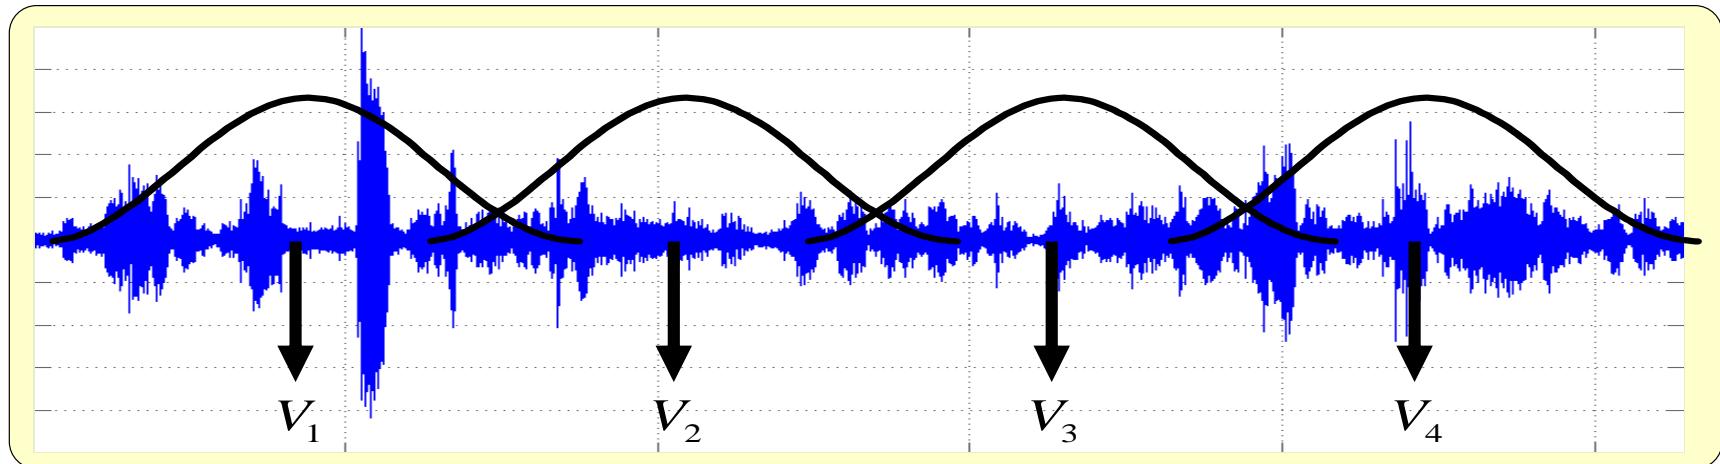
Étapes de calcul des coefficients MFCC (Rabiner et Juang, 1993)

Nature du signal de parole

Fenêtrage

MFCC

Paramètres utilisés



- Statiques : S_1, S_2, \dots, S_{12} (MFCC)
- Énergie statique : E_s
- Dynamiques : D_1, D_2, \dots, D_{12}
- Énergie dynamique : E_d

Pour chaque trame (fenêtre d'analyse) :

$$\underbrace{[S_1, S_2, \dots, S_{12}]}_{\text{statique (mfcc)}}, \underbrace{E_s}_{\text{énergie statique}}, \underbrace{[D_1, D_2, \dots, D_{12}]}_{\text{dynamique}}, \underbrace{E_d}_{\text{énergie dynamique}}$$

(26 coefficients)

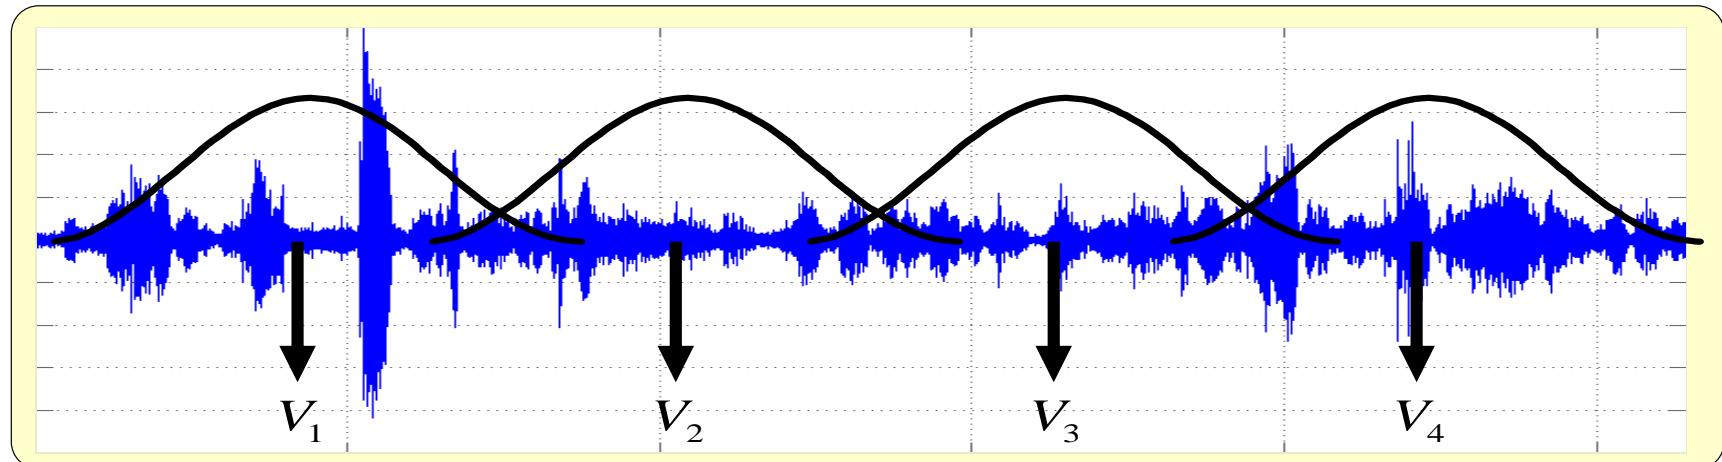
Que faire pour un signal ayant 4 trames ?

Nature du signal de parole

Fenêtrage

MFCC

Paramètres utilisés



Pour un signal ayant 4 trames : V_1, V_2, V_3, V_4

$$V = \begin{bmatrix} S_{1,1}, S_{1,2}, \dots, S_{1,12}, & E_{1s}, & D_{1,1}, D_{1,2}, \dots, D_{1,12}, & E_{1d} \\ S_{2,1}, S_{2,2}, \dots, S_{2,12}, & E_{2s}, & D_{2,1}, D_{2,2}, \dots, D_{2,12}, & E_{2d} \\ S_{3,1}, S_{3,2}, \dots, S_{3,12}, & E_{3s}, & D_{3,1}, D_{3,2}, \dots, D_{3,12}, & E_{3d} \\ S_{4,1}, S_{4,2}, \dots, S_{4,12}, & E_{4s}, & D_{4,1}, D_{4,2}, \dots, D_{4,12}, & E_{4d} \end{bmatrix}$$

Cela correspond à une entrée de 4×26 paramètres

- Dans le cadre du laboratoire, commencez par les paramètres statiques (12 paramètres par trame)
- Comme travail optionnel, on pourrait utiliser tous les paramètres (statiques et dynamiques)

Répartition

Type de données

Avant / Après Conversion

Bases de données

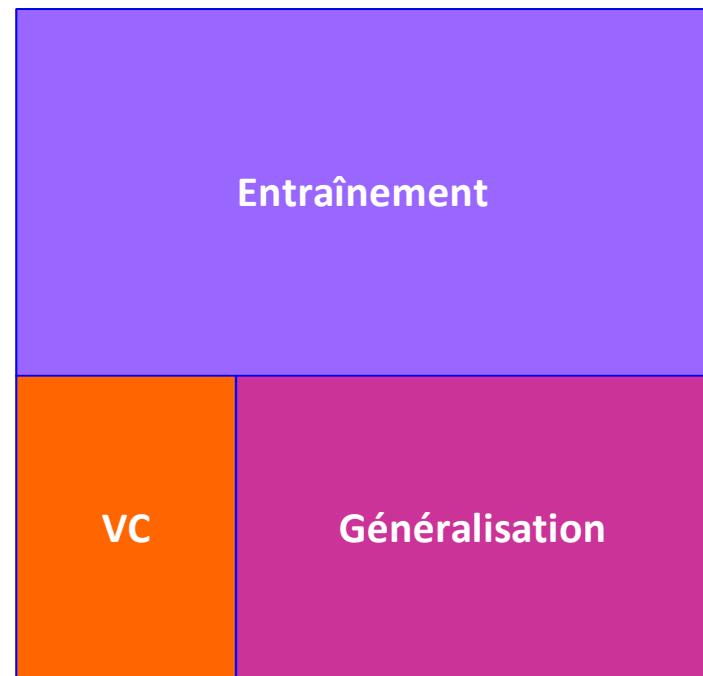
Informations sur la base de données :

- Les données sont réparties en 3 catégories :

- 1) Entrainement (apprentissage)
- 2) Validation croisée
- 3) Test de généralisation

- La répartition des données se trouve dans le répertoire **info_data** :

- **info_train.txt** : contient la liste des données (fichiers) pour l'apprentissage
- **info_vc.txt** : contient la liste des fichiers pour la validation croisée
- **info_test.txt** : contient la liste des fichiers pour le test de généralisation



Répartition

Type de données

Avant / Après Conversion

Base de données

1a.wav 1b.wav
2a.wav 2b.wav
...
9a.wav 9b.wav
oa.wav 0b.wav

man

woman

ae aj ●● st

ac ag ●● sp

55 locuteurs
2 répétitions

57 locutrices
2 répétitions

Repartition

Apprentissage

VC

Test

info_train.txt
(1340 données)
• man:660
• woman:680

info_vc.txt
(120 données)
• man:60
• woman:60

info_test.txt
(780 données)
• man:380
• woman:400



Répartition

Type de données

Avant / Après Conversion

Entête (header)

- info_train.txt

57 train/man/ha/8b.txt

59 train/man/ha/4a.txt

59 train/man/ha/ob.txt

61 train/man/aj/2b.txt

61 train/man/it/2b.txt

62 train/man/aj/1b.txt

62 train/man/ha/2b.txt

62 train/woman/eg/8b.txt

63 train/man/ha/oa.txt

65 train/man/aj/1a.txt

65 train/man/aj/3b.txt

65 train/man/ha/4b.txt

65 train/man/it/2a.txt



NIST_1A 1024

database_id -s8 TIDIGITS

database_version -s3 1.0

utterance_id -s6 ha_8_b

channel_count -i 1

sample_count -i 11776

sample_rate -i 20000

sample_min -i -1659

sample_max -i 2364

sample_n_bytes -i 2

sample_byte_format -s2 01

sample_sig_bits -i 16

speaker_id -s2 ha

prompt_code -s1 8

utterance_production -s1 b

recording_date -s11 15-JUL-1982

end_head

Nombre de trames : 57

Mot prononcé : 8 (eight)

Répartition

Type de données

Avant / Après Conversion

- info_train.txt
57 train/man/ha/8b.txt

Ligne 1 (trame 1) { -6.785384e+00 -2.439699e+00 -8.893854e+00 -6.788761e+00 5.160503e+00 3.697916e+00
 7.243154e+00 2.016473e+00 4.590659e+00 6.813693e+00 -2.607599e+00 4.110450e+00 -
 1.134814e-01 -1.147757e-01 3.345045e-01 1.698681e-01 5.829000e-01 -7.146162e-01 -
 1.040522e+00 -1.475640e+00 -6.800541e-01 8.455756e-02 -1.175227e+00 -4.345238e-01 -
 5.065219e-01 8.969450e-03

Ligne 2 (trame 2) { -7.583665e+00 -1.479346e+00 -8.630378e+00 -2.991285e+00 4.616855e+00 4.277121e-01
 1.831902e+00 -2.219958e+00 4.970704e+00 7.269855e+00 -1.422976e+00 2.214219e+00 -
 8.479893e-02 -4.761591e-01 -1.880742e-02 1.276574e-01 8.844274e-01 -7.473347e-01 -
 7.809860e-01 -7.301049e-01 -1.371514e+00 -1.439842e-01 3.125768e-01 3.292378e-01
 1.056775e-01 9.104836e-03

●
 ●

Ligne 57 (trame 57) { -5.001660e+00 3.509410e+00 -3.024056e+00 2.012576e+00 9.698270e+00 2.662062e+00
 3.227849e+00 -4.134442e+00 6.171534e+00 4.405443e+00 -6.717266e+00 -2.741660e-01 -
 8.662212e-02 -4.564412e-01 -2.203409e-01 5.941224e-01 1.189348e+00 9.793396e-01 -
 3.815369e-01 1.014225e-01 -6.284602e-01 8.625444e-01 -8.555050e-02 4.655319e-01
 2.363525e-01 -8.272087e-03



Répartition

Type de données

Avant / Après Conversion

Avant conversion

- info_train.txt
 - 57 train/man/ha/8b.txt
 - 59 train/man/ha/4a.txt
 - 59 train/man/ha/ob.txt
 - 61 train/man/aj/2b.txt
 - 61 train/man/it/2b.txt
 - 62 train/man/aj/1b.txt
 - 62 train/man/ha/2b.txt
 - 62 train/woman/eg/8b.txt
 - 63 train/man/ha/oa.txt
 - 65 train/man/aj/1a.txt
 - 65 train/man/aj/3b.txt

Après conversion

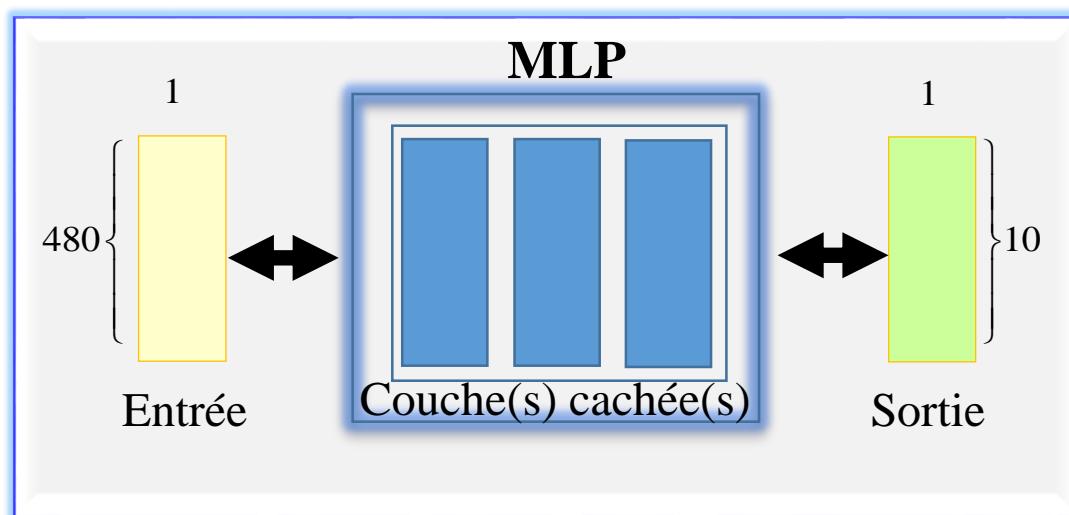
- info_train.txt
 - 40 train/man/ha/8b.txt
 - 40 train/man/ha/4a.txt
 - 40 train/man/ha/ob.txt
 - 40 train/man/aj/2b.txt
 - 40 train/man/it/2b.txt
 - 40 train/man/aj/1b.txt
 - 40 train/man/ha/2b.txt
 - 40 train/woman/eg/8b.txt
 - 40 train/man/ha/oa.txt
 - 40 train/man/aj/1a.txt
 - 40 train/man/aj/3b.txt

NB : Chaque fichier est une entrée.

Exemple 1

Exemple 2

Choix du code



Système de reconnaissance de la parole

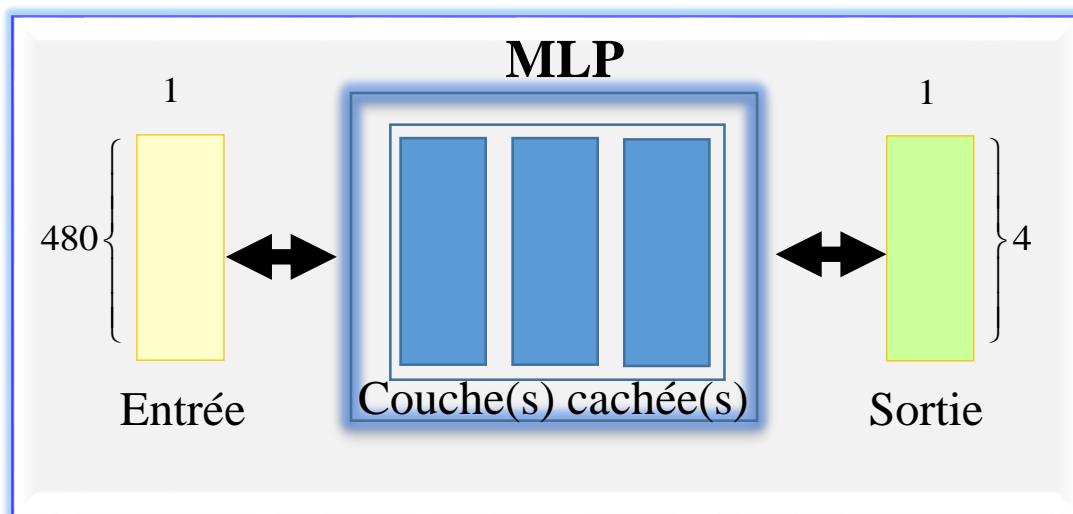
NbreMots:	10
NbreOutputs:	10
1:	1 0 0 0 0 0 0 0 0 0
2:	0 1 0 0 0 0 0 0 0 0
3:	0 0 1 0 0 0 0 0 0 0
4:	0 0 0 1 0 0 0 0 0 0
5:	0 0 0 0 1 0 0 0 0 0
6:	0 0 0 0 0 1 0 0 0 0
7:	0 0 0 0 0 0 1 0 0 0
8:	0 0 0 0 0 0 0 1 0 0
9:	0 0 0 0 0 0 0 0 1 0
o:	0 0 0 0 0 0 0 0 0 1

Important : l'application est indépendante du système (NN dans notre cas)

Exemple 1

Exemple 2

Choix du code



Système de reconnaissance de la parole

NbreMots:	10
NbreOutputs:	4
1:	0 0 0 1
2:	0 0 1 0
3:	0 0 1 1
4:	0 1 0 0
5:	0 1 0 1
6:	0 1 1 0
7:	0 1 1 1
8:	1 0 0 0
9:	1 0 0 1
o:	1 1 0 0



Exemple 1

Exemple 2

Choix du code

Quel est le meilleur des deux code de sortie ?

NbreMots: 10

NbreOutputs: 10

1: 1 0 0 0 0 0 0 0 0 0

2: 0 1 0 0 0 0 0 0 0 0

3: 0 0 1 0 0 0 0 0 0 0

4: 0 0 0 1 0 0 0 0 0 0

5: 0 0 0 0 1 0 0 0 0 0

6: 0 0 0 0 0 1 0 0 0 0

7: 0 0 0 0 0 0 1 0 0 0

8: 0 0 0 0 0 0 0 1 0 0

9: 0 0 0 0 0 0 0 0 1 0

o: 0 0 0 0 0 0 0 0 0 1

NbreMots: 10

NbreOutputs: 4

1: 0 0 0 1

2: 0 0 1 0

3: 0 0 1 1

4: 0 1 0 0

5: 0 1 0 1

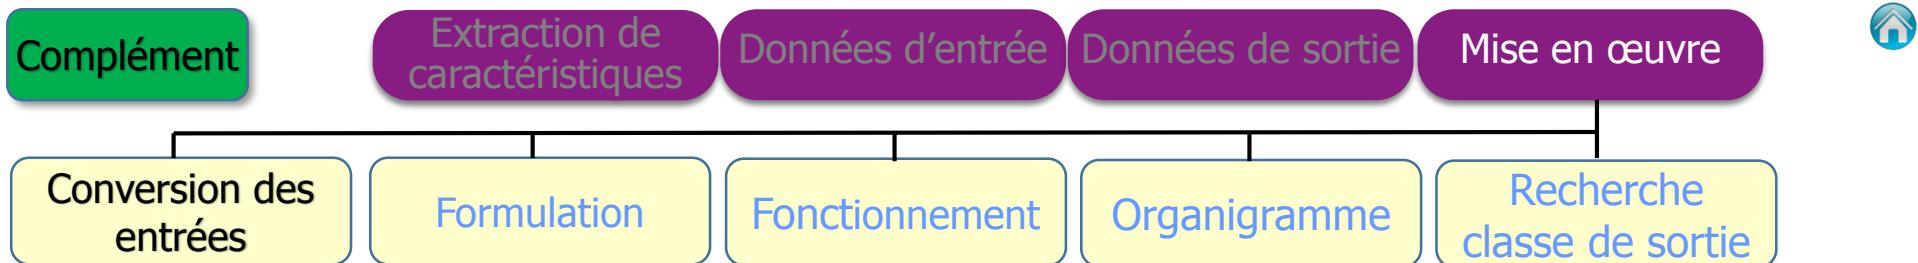
6: 0 1 1 0

7: 0 1 1 1

8: 1 0 0 0

9: 1 0 0 1

o: 1 1 0 0



- Chaque entrée doit avoir une taille fixe
- Si on veut utiliser 40 lignes et ne garder que les paramètres statiques :
 - Chaque forme d'entrée aurait une dimension de $40 \times 12 = 480$
 - Trouver une façon d'éliminer les lignes les moins significatives :
 1. utilisez l'énergie E_s
 2. utilisez l'énergie dynamique E_d
 3. toute autre méthode d'interpolation et/ou extrapolation



Complément

Extraction de caractéristiques

Données d'entrée

Données de sortie

Mise en œuvre

Conversion des entrées

Formulation

Fonctionnement

Organigramme

Recherche classe de sortie

train/man/ha/8b.txt

statique

E(statique)

dynamique

E(dynamique)

-6.785384e+00 -2.439699e+00 -8.893854e+00 -6.788761e+00
 5.160503e+00 3.697916e+00 7.243154e+00 2.016473e+00 4.590659e+00
 6.813693e+00 -2.607599e+00 4.110450e+00 **-1.134814e-01** -1.147757e-
 01 3.345045e-01 1.698681e-01 5.829000e-01 -7.146162e-01 -
 1.040522e+00 -1.475640e+00 -6.800541e-01 8.455756e-02 -
 1.175227e+00 -4.345238e-01 -5.065219e-01 **8.969450e-03**

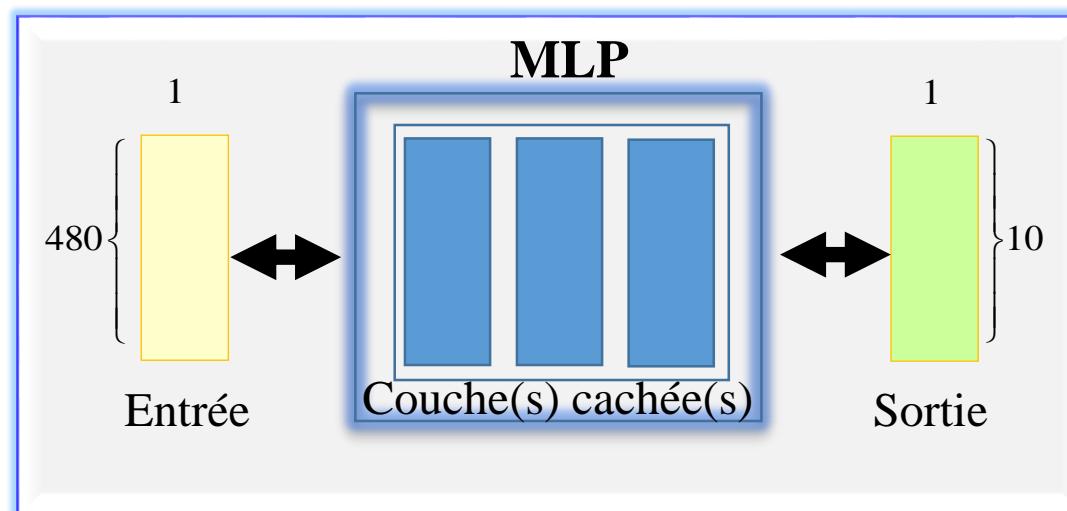
-7.583665e+00 -1.479346e+00 -8.630378e+00 -2.991285e+00
 4.616855e+00 4.277121e-01 1.831902e+00 -2.219958e+00 4.970704e+00
 7.269855e+00 -1.422976e+00 2.214219e+00 **-8.479893e-02** -4.761591e-
 01 -1.880742e-02 1.276574e-01 8.844274e-01 -7.473347e-01 -
 7.809860e-01 -7.301049e-01 -1.371514e+00 -1.439842e-01 3.125768e-
 01 3.292378e-01 1.056775e-01 **9.104836e-03**

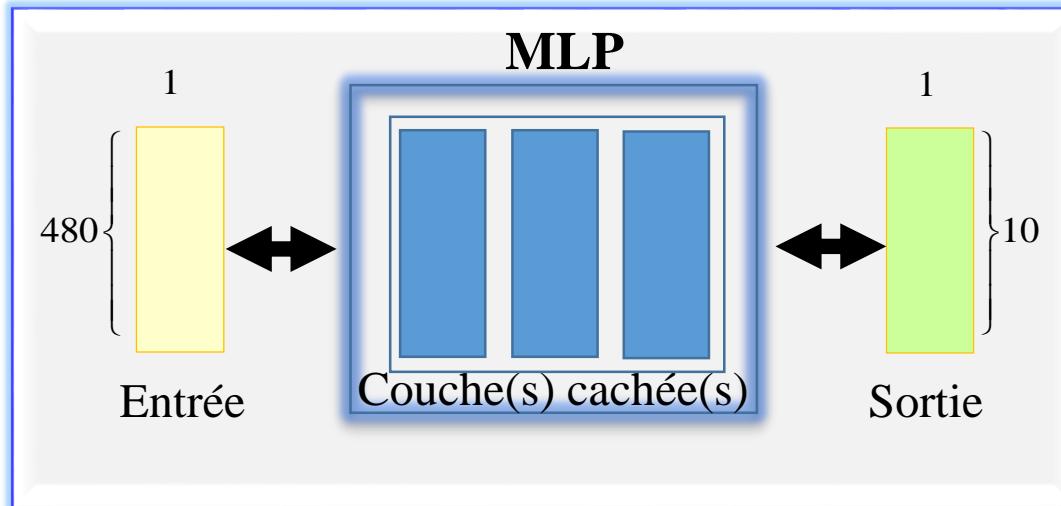
Formulation :

- Chaque forme d'entrée aura une dimension de 40 ligne x 12 statiques = 480 paramètres (former **1 vecteur colonne**)
- Définir la taille du réseau de neurones (nombre de couches, nombre de neurones par couche)
- Définir particulièrement le nombre de neurones à la sortie : le plus souvent 10 neurones
- Définir le code de sortie
- Définir la fonction d'activation, le taux d'apprentissage
- Initialiser aléatoirement les poids [-0.1, +0.1]

1 Fichier = 1 Entrée de Dim 480

1:	1	0	0	0	0	0	0	0	0	0	0
2:	0	1	0	0	0	0	0	0	0	0	0
3:	0	0	1	0	0	0	0	0	0	0	0
4:	0	0	0	1	0	0	0	0	0	0	0
5:	0	0	0	0	1	0	0	0	0	0	0
6:	0	0	0	0	0	1	0	0	0	0	0
7:	0	0	0	0	0	0	1	0	0	0	0
8:	0	0	0	0	0	0	0	1	0	0	0
9:	0	0	0	0	0	0	0	0	1	0	0
0:	0	0	0	0	0	0	0	0	0	0	1





Fonctionnement :

Définir K, le nombre de cycles d'apprentissage pour faire le test de validation croisée.

- 1) Piger une entrée au hasard (eg. train/man/ha/4a.txt)
- 2) Dérouler l'algorithme d'apprentissage (4 phases)
- 3) Trouver la sortie des 10 neurones, déterminer le code correspondant
 - a) Réussite : ne rien faire
 - b) Échec : faire l'apprentissage (règle de delta généralisée)
- 4) Critère d'arrêt atteint : FIN, sinon aller au 1).



info_train.txt

40 train/man/ha/8b.txt
40 train/man/ha/4a.txt
40 train/man/ha/ob.txt
⋮

1

aléatoire

info_VC.txt

40 vc/man/kd/2a.txt
40 vc/man/jt/2b.txt
40 vc/man/jt/ob.txt
⋮

2

séquentiel

info_test.txt

40 test/man/nr/8b.txt
40 test/woman/ng/8a.txt
40 test/man/rd/8a.txt
⋮

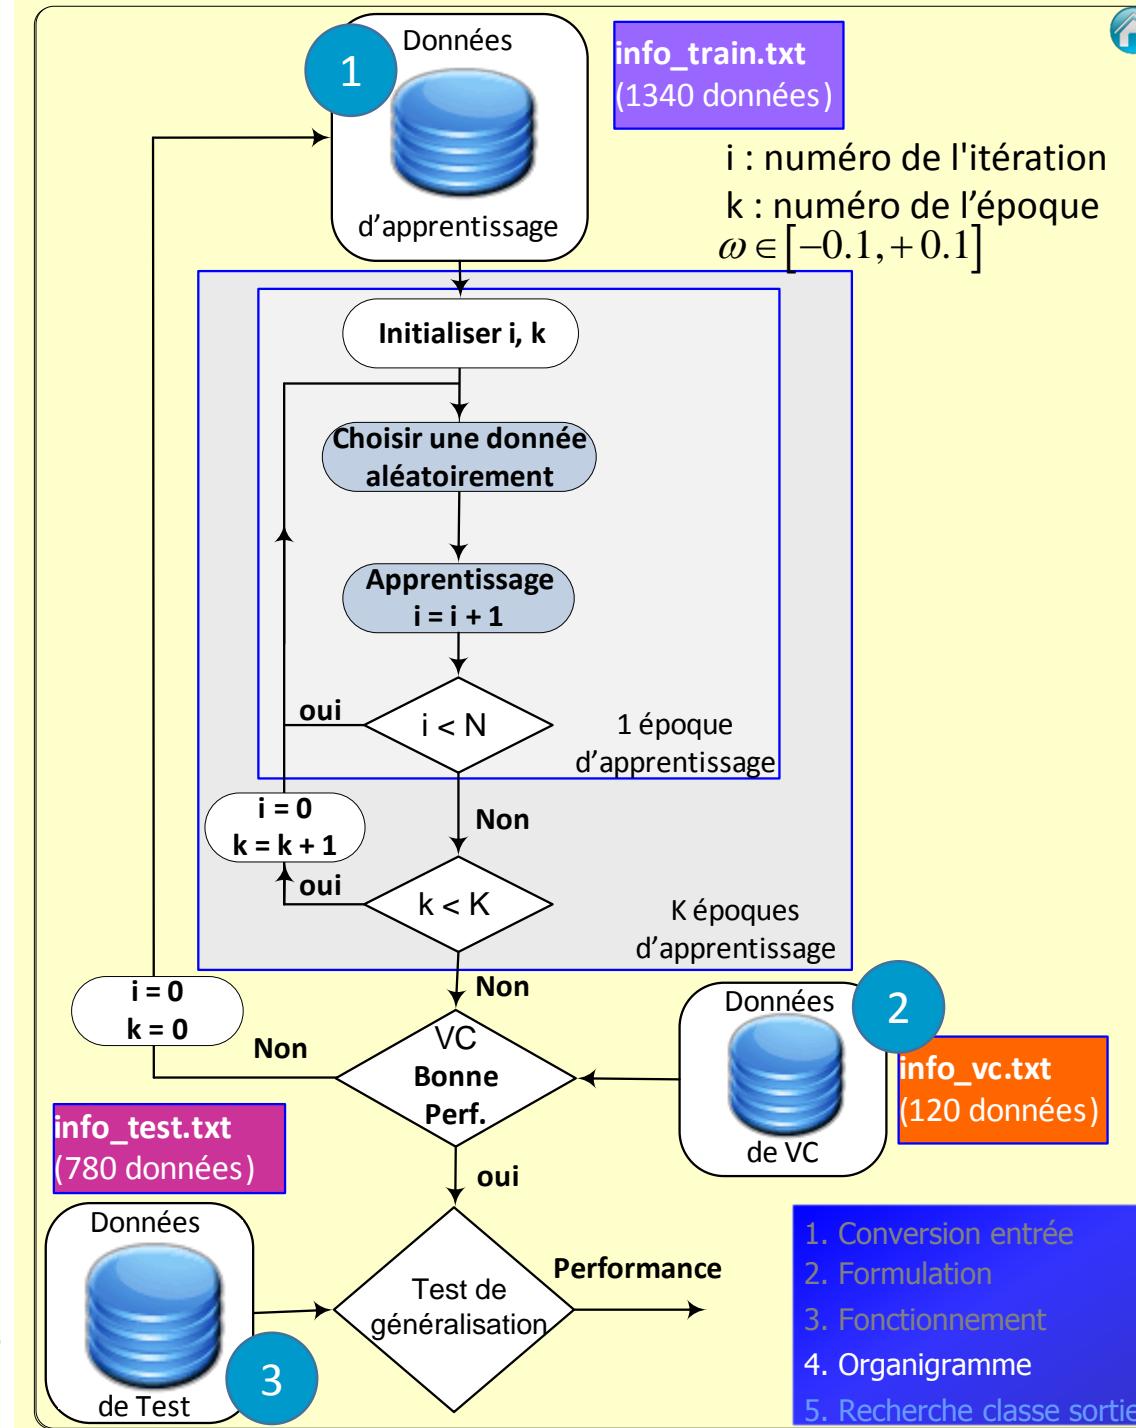
3

séquentiel

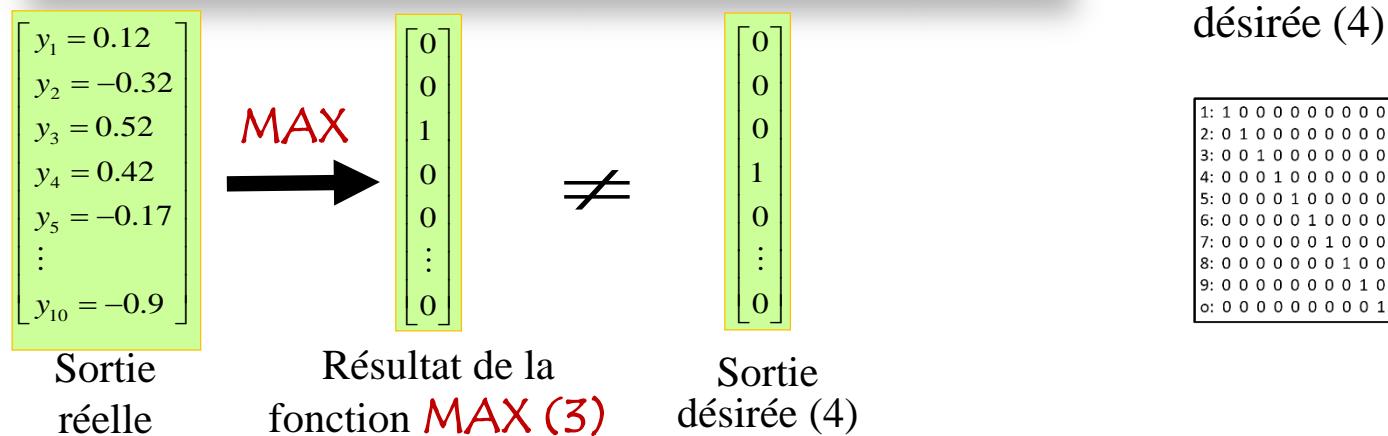
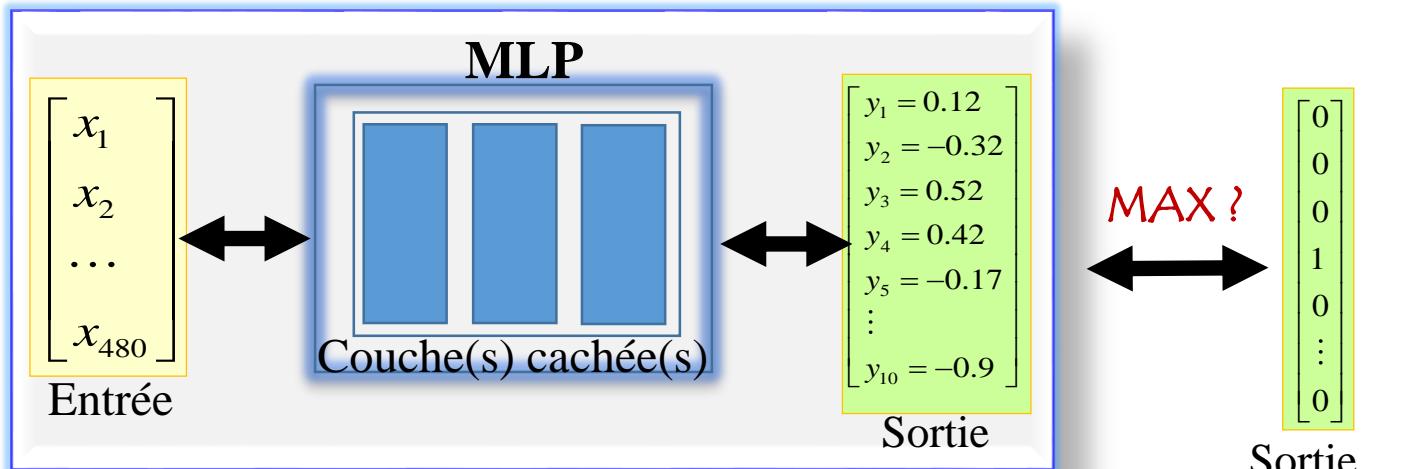
N = nombre de données disponibles pour l'apprentissage

1 cycle (époque) = N données disponibles pour l'apprentissage

K = nombre de cycles d'apprentissage avant la VC



train/man/ha/4a.txt



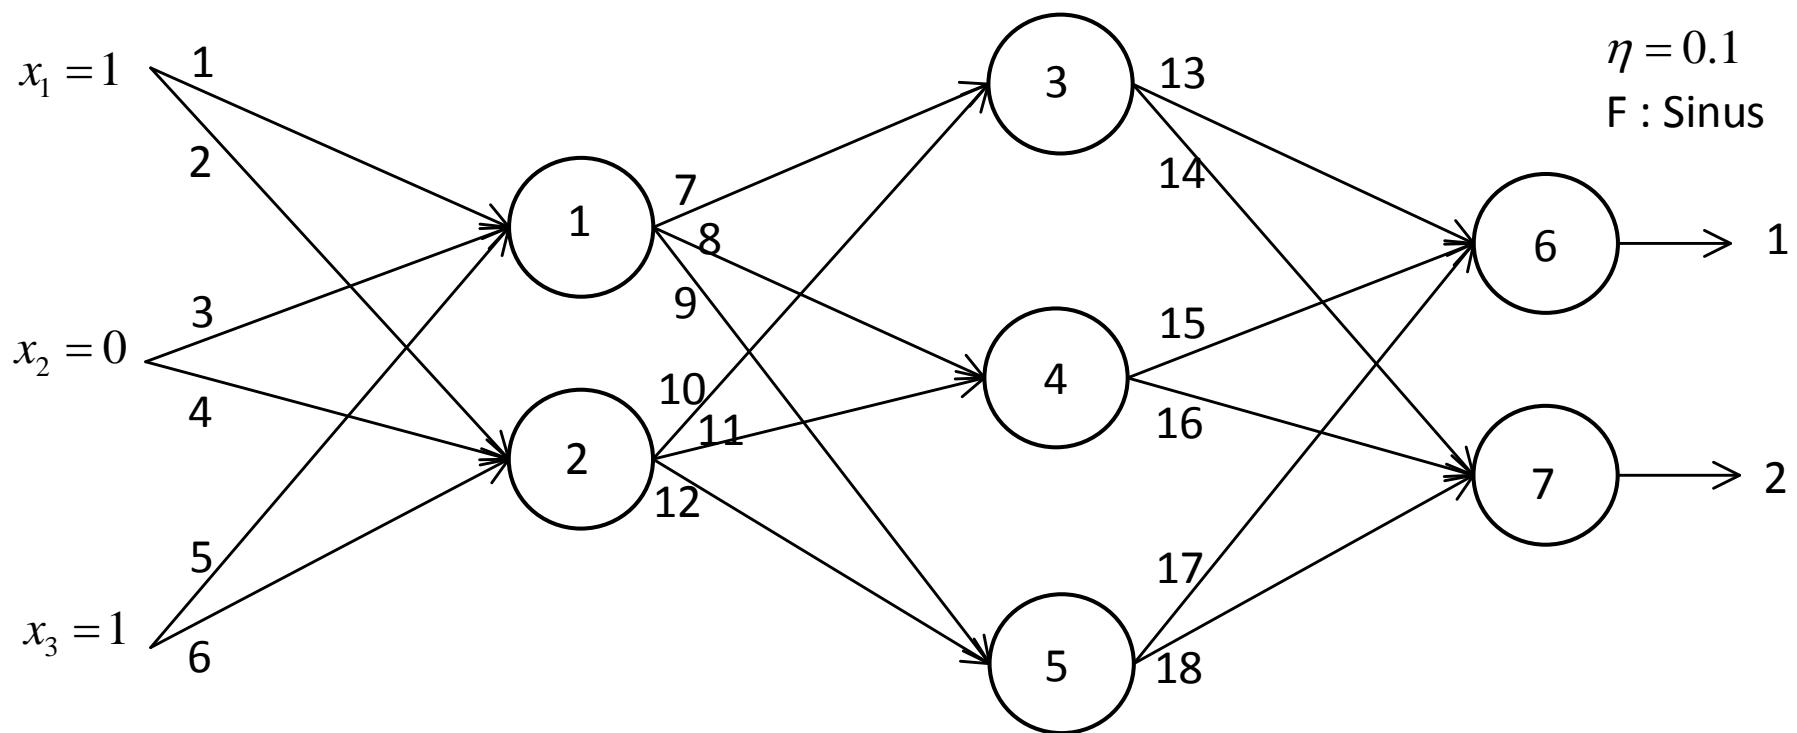
1:	1	0	0	0	0	0	0	0	0	0	0
2:	0	1	0	0	0	0	0	0	0	0	0
3:	0	0	1	0	0	0	0	0	0	0	0
4:	0	0	0	1	0	0	0	0	0	0	0
5:	0	0	0	0	1	0	0	0	0	0	0
6:	0	0	0	0	0	1	0	0	0	0	0
7:	0	0	0	0	0	0	1	0	0	0	0
8:	0	0	0	0	0	0	0	1	0	0	0
9:	0	0	0	0	0	0	0	0	1	0	0
0:	0	0	0	0	0	0	0	0	0	0	1

- La sortie réelle étant différente de la sortie désirée \Rightarrow Apprendre la donnée ha/4a.txt
- Important :** lors de la mise à jour des poids, on doit utiliser les valeurs de la sortie réelle, et non pas le résultat de la fonction MAX.



Quelques démonstrations

Exercice*



Apprentissage

Trouver les nouvelles valeurs des poids du réseau en appliquant la règle de delta généralisée

- * Cet exercice (diapositive) n'est pas à la bonne place ! C'est juste pour ne pas modifier la pagination de vos notes de cours !

Transformée en cosinus discrète (DCT)

- DCT est une transformation orthogonale comme la DFT, avec coefficients réels.
- Assumption de la périodicité plus réaliste que la DFT !!!
- Propriété de compaction de l'énergie : d'où son utilisation en compression

$$1D : X(k) = \alpha(k) \sum_{n=0}^{N-1} x[n] \cos\left(\frac{(2n+1)k\pi}{2N}\right), \quad 0 \leq k \leq N-1$$

$$2D : X(k_1, k_2) = \alpha(k_1)\alpha(k_2) \sum_{n_1=0}^{N-1} \sum_{n_2=0}^{N-1} x[n_1, n_2] r(n_1, n_2, k_1, k_2)$$

